ESIGELEC
ÉCOLE D'INGÉNIEURS-ES GÉNÉRALISTES

TP 2 – API “Digital Social Score”

De la menace à la défense : renforcer une IA déployée dans le cloud

1 - Objectif global

À partir de votre projet **Digital Social Score** (TP n°1), vous devez :

- **Simuler une attaque sur le modèle IA**
- **Concevoir et prouver l’efficacité d’une défense adaptée,**
- **Mettre en œuvre un pipeline DevSecOps sécurisé,**
- **Démontrer la conformité de votre modèle au règlement IA Act.**

Étape 1 : Choix et analyse d’une attaque

Objectifs pédagogiques :

Identifier la surface d’attaque de votre modèle IA et comprendre les menaces possibles sur une API exposée publiquement.

Exercice :

- Choisissez une seule attaque à reproduire
- Décrivez :
  - Ce que l’attaquant cherche à obtenir
  - Le point d’entrée exploité.
  - L’impact attendu (technique, éthique et RGPD).

Livrable :

- Une fiche d’analyse “Attaque IA” (1 page maximum).
  - Type d’attaque
  - Cible
  - Objectif de l’attaquant
  - Impact attendu
  - Risque IA Act

Étape 2 : Mise en oeuvre de l'attaque

Objectif pédagogique :

- Simuler concrètement une attaque IA et observer son impact mesurable.

Exercice :

- Créez un dossier /attack dans votre projet.
- Créez-y un script d'attaque correspondant à votre choix.
- Lancez l'attaque.
- Mesurez l'impact
  - Précision du modèle
  - Taux de faux positifs
  - Latence

Livrables :

- Graphique des métriques
- Interprétation des résultats.

Étape 3 : Conception d'une défense

Objectif pédagogique :

- Appliquer des contre-mesures concrètes et valider leur efficacité.

Exercice :

- Selon le type d'attaque choisi, implémentez une défense
- Réexécutez l'attaque initiale après correction.
  - Mesurez les performances avec et sans défense.
  - Comparez les résultats dans un tableau.

Livrables :

- Un tableau des métriques avant/après.
- Graphique de comparaison

Étape 4 : Conformité IA Act

Objectif pédagogique :

- Évaluer votre modèle au regard du **cadre européen IA Act** et formaliser votre conformité.

Exercice :

- Identifiez et justifiez la catégorie de risque de votre modèle de classification.
- Créez une "Model card"

```
{
    "model_name": "Digital Social Score v2",
```

```
    "description": "Detection de propos toxiques dans un texte",
    "risk_level": "à définir",
    "data_source": "source",
    "privacy_measures": ["anonymisation", "chiffrement logs"],
    "bias_detected": false,
    "version": "2.1",
    "last_update": "2025-11-07"
}
```

Livrables :

- Une fiche IA Act :
  - Tableau de risque et justification
- Un fichier model_card.json à la racine de votre projet.

Étape 5 : Intégration DevSecOps

Objectif pédagogique :

- Intégrer la sécurité et la conformité dans le pipeline CI/CD.

Exercice :

- Mettez à jour votre pipeline pour y intégrer une ou plusieurs étapes de sécurité.

2 - Livrables globaux du projet

- Type d'attaque et démonstration
- Défense et preuve d'efficacité
- Classification IA Act + Model Card
- Pipeline sécurisé + logs d'exécution
- Analyse critique et recommandations

3 - Critères d'évaluation

Compétence	Indicateurs
Réalisme de l'attaque	Pertinence, complexité technique
Efficacité de la défense	Mesure de l'impact
Conformité IA Act	Document complet et cohérent
Pipeline DevSecOps	Fonctionnel et automatisé
Rigueur et clarté	Documentation et structure
Originalité et réflexion	Créativité, approche critique